

Régression linéaire

Sommaire

I Principe	2
II Réalisation logicielle	2
II/A À la calculatrice	2
II/B En Python	4
III Pertinence du modèle	4
IV Autres cas	6
IV/A Cas strictement linéaire	6
IV/B Cas non linéaires	6

Capacités exigibles

- ☐ Analyser les résultats obtenus à l'aide d'une procédure de validation : analyse graphique intégrant les barres d'incertitude ou analyse des écarts normalisés.
- ☐ Utiliser un logiciel de régression linéaire afin d'obtenir les valeurs des paramètres du modèle.
- ☐ Utiliser la fonction `polyfit` de la bibliothèque `numpy` (sa spécification étant fournie) pour exploiter des données.

I Principe

La pratique de la science passe par deux pivots inséparables : la *théorie* et la *mesure*. La première pose un cadre de travail pour aboutir à des conclusions sur le fonctionnement du monde physique sous la forme de relations mathématiques, et la seconde relève des valeurs expérimentales du monde physique pour en archiver les propriétés effectives.

L'une et l'autre se nourrissent conjointement : une théorie physique pose une loi et la mesure permet de la tester, ou un relevé expérimental particulier permet de mettre en évidence un point sombre des cadres théoriques actuels. Il reste que les sciences physiques ont pour unique objectif de rendre compte du réel ; ainsi, si l'expérience est bien contrôlée, **c'est toujours la mesure qui clôt la discussion**.

Dans ce cadre, il est commun de disposer de deux jeux de données réelles représentant des **grandeurs reliées** entre elles par une loi physique (disons x et y), et normalement compatibles avec une **relation linéaire** mathématique :

$$y = ax + b$$

avec a et b des coefficients propres à la relation :

- ◇ a le *coefficient directeur* ;
- ◇ b l'*ordonnée à l'origine*.

La régression linéaire¹ vise à **tester l'accord entre mesure et théorie**, et le cas échéant à **estimer les coefficients** et leurs incertitudes. Elle repose sur la détermination de la meilleure droite qui serait susceptible de représenter le nuage de points donné en deux dimensions par x et y , en l'occurrence en minimisant la somme des distances au carré entre chacun des points et la droite. Cet **écart aux points mesurés** est caractérisé par un coefficient de corrélation, noté r , ou de régression, noté r^2 , et compris entre 0 (nul) et 1 (parfait).

Régression linéaire

Une régression linéaire est une **opération mathématique** entre des points de mesure x_i et y_i qui consiste à trouver les meilleurs coefficients a et b tels que les valeurs $ax_i + b$ soient les plus proches en moyenne des points de mesures y_i .

Cette régression peut être faite à la main, mais la détermination des coefficients ne sera pas rigoureuse. Nous allons ici détailler le processus pour une régression *via* un logiciel.

II Réalisation logicielle

II/A À la calculatrice

TI 83+

- ◇ Appuyer sur **stats**.
- ◇ Dans le menu EDIT choisir 1 : **Editer**.
- ◇ Entrer les deux séries de données : l'abscisse dans la première colonne L1, et l'ordonnée dans la seconde colonne L2.
- ◇ Dans le menu **graph stats**, choisir la première ligne.
- ◇ Choisir **Aff** pour afficher, puis le premier type, la liste L1 pour **ListeX** et la liste L2 pour **ListeY**.

1. Il faudrait en toute rigueur parler de régression *affine* et non linéaire.

- ◇ Appuyer sur **graphe** pour afficher le nuage de points.
- ◇ Pour déterminer les coefficients a , b et r ou r^2 , retourner dans **stats** puis aller dans le menu **CALC** et choisir 4 : **RegLin(ax+b)**. Appuyer sur **ENTER**.

r non indiqué

Tracer la courbe

- ◇ Appuyer sur **2nde** puis **catalog**.
- ◇ Choisir **Diagnostic On** ou **corelAff** selon la langue, appuyer deux fois sur **ENTER**.
- ◇ Aller dans **f(x)**, appuyer sur **var**.
- ◇ Choisir 5 : **Statistiques**.
- ◇ Dans le menu **EQ** choisir 1, puis **ENTER**.
- ◇ Aller dans **graphe** pour voir la droite.

Casio 35+

- ◇ Aller dans le mode **STAT**.
- ◇ Entrer les deux séries de données dans **List1** et **List2**.
- ◇ Appuyer sur **GRAPH** puis **SET**.
- ◇ Choisir le type de graphique **GraphType** : **Scatter**. Mettre **List1** dans **XList** pour l'abscisse et **List2** dans **YList** pour l'ordonnée.
- ◇ Appuyer sur **ENTER**, et appuyer sur **GRAPH** 1 pour visualiser le nuage de points.
- ◇ Appuyer sur **CALC** puis **X** puis sur **ax+b** pour obtenir une régression linéaire $y = ax + b$.
- ◇ Une fenêtre **LinearReg** affiche la pente a , l'ordonnée à l'origine b et le coefficient de corrélation r^2 .
- ◇ Pour visualiser la droite, choisir **DRAW** en bas à droite.

Attention !

Il est plus que courant d'inverser les deux listes !

Numworks

- ◇ Aller dans le mode **Régressions**
- ◇ Rentrer les séries de données en **X1** et **Y1**.
- ◇ Aller dans le menu **Graphiques**, puis **Régression** (à côté de **Naviguer** en haut de la fenêtre)
- ◇ Choisir le modèle **Affine** (ou **Linéaire**)
- ◇ Observer la droite, puis vous avez deux choix :
 - 1) Retourner dans **Régression** et lire l'équation de la droite, en déduire a et b si la régression est validée (voir plus loin) ;
 - 2) Aller dans le menu **Stats** à côté de **Graphique**, et déplacer le curseur sur la liste **Y1** puis vers le bas pour une meilleure lecture des paramètres.

II/B En Python



```

1 x = np.array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10]) # unité
2 ux = 0.1 * np.ones(len(x)) # incertitude de 0.1 sur chaque valeur
3
4 y = np.array(
5     [2.20, 2.00, 1.60, 1.55, 1.16, 1.00, 0.95, 0.60, 0.36, 0.36, 0.18]
6 ) # unité
7 uy = 0.12 * np.ones(len(y)) # incertitude de 0.12 sur chaque valeur
8
9 Delta_x = ux * np.sqrt(3) # demi-largeur x
10 Delta_y = uy * np.sqrt(3) # demi-largeur y
11
12 N = 10000 # nombre de régressions à effectuer
13
14 liste_a, liste_b = [], [] # création des listes vides pour stocker les valeurs
15 for i in range(N):
16     # on prend des valeurs de x_simu parmi toutes les valeurs possibles
17     # à l'aide d'un tirage aléatoire à l'intérieur de l'intervalle
18     # [x ± Delta_x]
19     x_simu = x + Delta_x * np.random.uniform(-1, 1)
20     # Pareil pour y
21     y_simu = y + Delta_y * np.random.uniform(-1, 1)
22
23     # On fait une régression linéaire avec ces données « simulées »
24     a_simu, b_simu = np.polyfit(x_simu, y_simu, 1)
25
26     # On les sauvegarde dans les listes correspondantes
27     liste_a.append(a_simu)
28     liste_b.append(b_simu)
29
30 # Les valeurs moyennes sont les moyennes des listes
31 a_moy, b_moy = np.mean(liste_a), np.mean(liste_b)
32 # Les incertitudes sont l'écart-type des listes
33 ua, ub = np.std(liste_a, ddof=1), np.std(liste_b, ddof=1)
34
35 # Affichage, à modifier pour l'écriture scientifique
36 print(f"Coef.directeur = {a_moy:.3e} +- {ua:.3e}")
37 print(f"Ordonnée à l'origine = {b_moy:.3e} +- {ub:.3e}")

```

III Pertinence du modèle

Une fois la régression effectuée, il faut juger de sa validité. En effet, **une régression linéaire va toujours « fonctionner »**, mais ceci n'assure en rien qu'elle est bonne.

Attention!!

La seule façon valable de conclure à la validité d'une régression linéaire est d'observer l'alignement des points avec la droite de régression.

Une erreur des plus basiques est de ne considérer que l'accord numérique *via* la valeur de r ou r^2 . S'il est *nécessaire* d'avoir et d'écrire

$$|r| > 0,999x \quad \text{ou} \quad r^2 > 0,99x$$

où x représente le premier chiffre autre qu'un 9, il est loin d'être *suffisant* et c'est la vérification visuelle qui prévaut.

Ma régression est-elle valide ?

Le modèle sera validé sous deux conditions :

- 1) les points de mesure sont **bien alignés** entre eux (pas de courbure visible à l'œil) ;
- 2) la **droite** de régression passe le **plus proche de tous les points** possibles, en **incluant leurs incertitudes-type**.

Application : quel modèle est validé ?

On présente ci-après des données et leur régression associée. Pour chaque modèle, dire si la régression est validée ou non, et expliquer pourquoi.

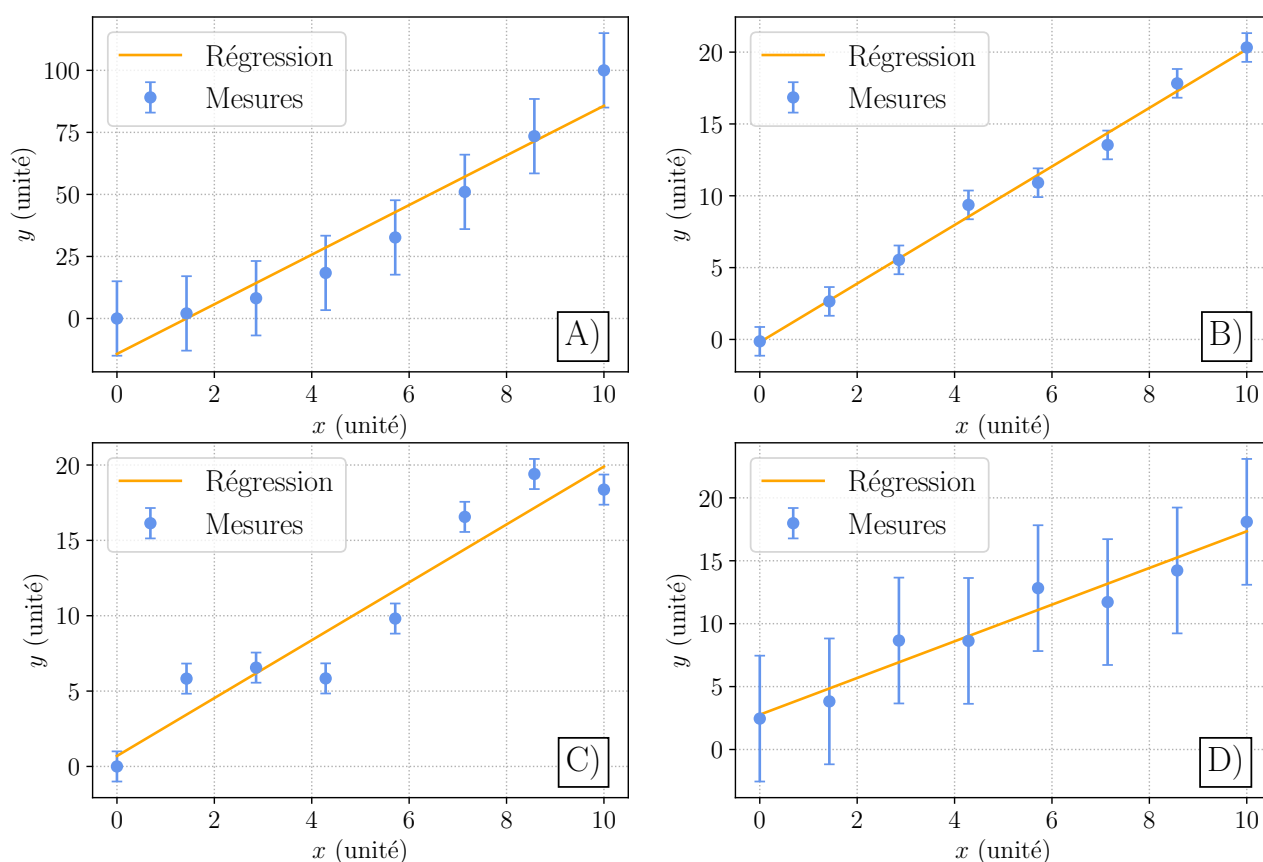


FIGURE 3.1 – Exemples de régressions linéaires.

- A)
B)
C)
D)

IV Autres cas

IV/A Cas strictement linéaire

Si le modèle recherché implique $b = 0$, dans ce cas, on cherche uniquement à estimer a . On peut donc calculer un grand nombre de valeur de a par la relation y_i/x_i , puis réaliser un traitement statistique sur ces valeurs.

Le grand intérêt est que, dans ce cas, les N points de mesures conduisent à N valeurs de a ayant une variabilité claire, et permettant donc une incertitude de type A.

IV/B Cas non linéaires

Dans de nombreux cas, la loi à vérifier n'est ni affine ni linéaire. C'est le cas de la loi de SNELL-DESCARTES sur la réfraction entre deux milieux d'indice optique n_1 et n_2 :

$$n_1 \sin(i_1) = n_2 \sin(i_2)$$

Avec des mesures de i_1 et de i_2 , il n'est pas possible d'obtenir directement une droite. Il faut dans ce cas tracer :

L'adaptation en Python est relativement directe grâce à la librairie `numpy` (voir fiche Python), mais il faut apprendre à maîtriser les opérations sur des listes *via* les calculatrices.

TI 83+

- ◇ Aller sur la case L3, puis ENTER
- ◇ Entrer la formule (L3=sin(L2) ici), puis ENTER

Casio 35+

- ◇ Dans menu RUN, touche OPTN et LIST
- ◇ Entrer la formule (sin(List2) → List3 ici), puis EXE

Numworks

- ◇ Aller sur le nom de la liste à modifier, par exemple Y2.
- ◇ Appuyer sur OK puis Remplir avec une formule.
- ◇ Choisir Vide, puis écrire `sin(Y1)` à l'aide des touches `shift` et `alpha`, puis OK.

Attention !

N'allez pas trop vite, vous risqueriez de finir par trier une liste, qui sera ensuite impossible à « dé-trier » !